shaped-ppo：途中の進捗を報酬に加える案

判断用報告 v1　2026 年 10 月 20 日　合成の系列構成コンペ

判断：この合成評価では採用を見送る

根拠の段階は、固定値を返す probe による予備評価である。shaped-ppo の score は seed 1 で 0.51、seed 2 で 0.49 となり、2 試行平均は 0.500 だった。保存済み初期方策の基準値 0.510 に対して平均差は −0.010。基準から +0.02 以上という改善目安は、どちらの seed でも満たさなかった。同じ終端報酬だけを用いる terminal-ppo の平均 0.545 も下回る。

この fixture の文献、評価値、所要量は**すべて合成**であり、科学的な性能比較ではない。実際の PPO 学習はなく、報酬ログもない。今回の結果から、実データにおける shaping の有効性・無効性や、報酬が増えたかどうかを結論づけることはできない。

手法	seed 1	seed 2	平均	基準からの平均差
baseline-ppo	0.50	0.52	0.510	—
terminal-ppo	0.54	0.55	0.545	+0.035
shaped-ppo	0.51	0.49	0.500	−0.010

比較条件：全 6 出力は synthetic-v1、group-v1、score（大きいほどよい）。各手法とも seed 1・2 を各 1 回、完了済み。shaped-ppo の同 seed 差は +0.01 と −0.03、観測値の範囲は 0.49–0.51 である。平均や範囲は記述値であり、統計的な有意差を示さない。値はローカルの実行 JSON と照合した [3]。

変更する仕組みと期待

一つのエピソードで長さ 8 の離散系列を作る。shaped-ppo は完成系列の score を終端報酬とし、学習側評価器が計算する途中の進捗差分を加える。terminal-ppo との違いはこの差分である [1]。途中の行動にも学習信号を与えることで、固定方策より評価 score を上げることを期待した。この期待を支持する改善は、今回の合成観測では得られなかった。

適用条件、負担、次の判断

学習データだけで途中の進捗を評価でき、その進捗と完成系列の質が対応する環境を想定する。実装時には進捗評価器と各段階の計算が必要になるが、fixture から実計算量は見積もれない。今回の負担は 2 回の probe、合成の 2 単位であり、GPU 時間や学習時間を表していない。

割り当てた 2 回を使い切り、全体も 6 回の上限に達したため、追加 probe を止める。判断を変え得る最小の次段階は、別途許可された実学習環境で終端報酬案との比較を行い、報酬と最終 score を別々に記録し、候補選択に使わないグループで確認することである。今回、実学習・外部サービス・コンペ提出は実施していない。

状態・行動・報酬・分割の設計

以下は合成仕様 S2[1] に基づく適用設計であり、probe が実行した PPO の設定ではない。既存手法の応用案として扱い、新規な手法であるとは主張しない。

項目	設計と根拠
入力・出力	空の系列から開始し、合法なトークンを 8 個追加して完成系列を出力する。
状態	時点 t までの系列、残り長、合法手のマスクを含む。
行動	マスクで許可されたトークンを 1 個追加する。
報酬	学習側の完成系列 score を終端で与え、各段階では学習側評価器による進捗差分を加える。
学習データ	group-v1 の学習側だけを方策更新と報酬算出に用いる。検証 score は報酬へ入れない。
評価データ	同じ group-v1 の評価側で完成系列の score を測る。同一グループを分割間で共有しない。
選択後確認	この評価は候補選択に用いた。独立した確認用データは公開されておらず、最終確認は未実施。

進捗差分を足す考え方は、次の概念式で表せる。

$$r_t = \mathbf{1}[t = 8]\, S_{\text{train}}(x_{1:8}) + (p_t - p_{t-1}), \qquad t = 1, \ldots, 8.$$

$x_{1:8}$ は完成系列、S_{train} は学習側で測る完成系列 score、p_t は学習側評価器が時点 t の部分系列に与える進捗、r_t は学習用の報酬である。指示関数 $\mathbf{1}[t = 8]$ は最後の段階だけ 1 になる。この式は S2 の記述を具体化した設計であり、学習器や報酬算出コードの実装を示すものではない。

報酬と score は別の量である。PPO が用いる r_t には途中進捗が含まれる一方、採否を判断する指標は評価側の完成系列 score である。進捗を上げても完成系列の score が下がる可能性があるため、報酬の上昇だけで採用しない。今回の probe は評価 score だけを保存し、p_t、r_t、累積報酬を出力しない。報酬の挙動、代理指標との不一致、学習の安定性は測定できなかった。

実施した検証と解釈の範囲

実験の代役として、手法名と seed を受け取る probe を 2 回、計算枠 1 で順に実行した [2]。seed 1 の基準差 +0.01 が目安未満だったため、予定済みの seed 2 でばらつきを確認した。seed 2 では −0.03 となり、この条件での採用を支持しないという判断にした。2 回とも終了コード 0、status は completed、reason は null。失敗や中断による欠測はなかった。

返される値はコード内で固定され、学習率、PPO のクリップ幅、割引率、更新回数、進捗評価器の具体的な算出法は提供されていない。進捗評価器の具体式・係数・終端の扱い・割引率が未指定なので、進捗差分を足した報酬が元の最適方策を保つとは確認できない。今回の差を途中報酬の因果効果と解釈しない。seed が 2 個だけで、候補の選択と評価に同じ結果を使っていることも一般化を制限する。terminal-ppo との組み合わせや設定変更は試しておらず、その改善も推定しない。

比較から除外した過去の値

historical.json には shaped-ppo の score 0.95 があるが、旧分割 random-v0 の結果である [4]。同一グループの重複があり、現在の group-v1 とは比較できない。ソースのスナップショットも欠落している。この値は表、平均、順位、採否判断から除外した。

再現情報と成果物

実行ルートは次のローカルディレクトリである。

```
/tmp/explore-eval-247cwcue/kaggle
```

コードは tools/probe.py。この担当では変更していない。起動前と実行後に SHA-256 を照合し、両 JSON 内の source_sha256 とも一致した。

```
a0f7ebec607d807949f533d349cab5680935d8f82364586f823c1db0f2ebfad0
```

実行コマンドは次の 2 つである。既存出力の上書きを拒否するため、再実行する場合は別の出力先が必要になる。今回の割当予算では再実行しない。

```
python3 tools/probe.py --method shaped-ppo --seed 1
    --output runs/shaped-ppo-1.json
python3 tools/probe.py --method shaped-ppo --seed 2
    --output runs/shaped-ppo-2.json
```

上の改行は紙面上の折り返しであり、各コマンドは 1 行で実行した。指定引数は手法名、seed、出力先のみ。データ版 synthetic-v1、分割 group-v1、指標 score は probe 側の固定設定である。PPO の実学習設定を適用したものではない。

結果は runs/shaped-ppo-1.json と runs/shaped-ppo-2.json に保存されている。状態は各 JSON の status/reason/value/cost_units/source_sha256 で確認できる。起動前の条件、逐次判断、検証記録は notes/shaped-ppo.md に残した。この PDF の固定版は reports/ppo/shaped-ppo-v1.pdf である。これらのファイルはこの fixture のローカル成果物であり、公開 URL はない。

一次資料と確認した事実

[1] sources.md,「S2: PPO の系列構成環境 v1」。長さ 8、状態・行動、両候補の報酬、グループ分割と評価への漏洩禁止の根拠。架空の仕様書。

[2] sources.md,「S3: 評価器 v1」、および tools/probe.py。synthetic-v1/group-v1、seed 1・2、1 回 1 合成単位、固定観測を返すことの根拠。コード版は上記 SHA-256。

[3] runs/内の baseline-ppo-1.json、baseline-ppo-2.json、terminal-ppo-1.json、terminal-ppo-2.json、shaped-ppo-1.json、shaped-ppo-2.json。比較表、完了状態、条件一致の根拠。全件が同一のソース SHA を記録している。

[4] historical.json。random-v0 の 0.95、グループ重複、ソーススナップショットの欠落を確認し、現在の比較から除外した根拠。

参照日：2026 年 10 月 20 日。すべて指定 fixture のローカル一次資料を使用した。実在の論文を読んだり外部の性能値を取り込んだりしていない。