終端スコアを報酬にするPPO

架空の系列構成コンペ／ 2026 年 10 月 20 日／固定版 v1

判断：合成比較では有望。実データでの採用は保留

長さ 8 の離散系列を構成する既存方策を、完成系列の score を終端報酬として PPO で更新する案である。更新しない保存方策を基準にすると、2 つの seed とも改善の目安である +0.02 を満たした。次に実学習の確認へ進める候補として残す。

この報告の数値・資料はすべて合成であり、科学的成果や実コンペの改善を示さない。実行した probe は固定値を出力するだけで、PPO 学習を行っていない。根拠の段階は「合成の予備比較」である。

比較結果

指標は score（大きいほどよい）。全件 synthetic-v1、group-v1。同じ seed 同士の差を比較した。

seed	更新なし基準	終端報酬 PPO	基準との差
1	0.50	0.54	+0.04
2	0.52	0.55	+0.03
平均	0.510	0.545	+0.035

各条件 2 回、失敗・中断なし。候補の範囲は 0.54〜0.55、基準は 0.50〜0.52。平均差だけでなく両 seed の改善を確認した。ただし 2 個の固定値から統計的な有意性や再現性は判断できない。

仕組みと期待した効果

完成系列の良さを直接報酬にするため、学習の目的を最終 score に結び付けやすい。途中の行動には報酬を与えず、終端でのみ学習側の評価器を呼ぶ。比較対象との違いは、この報酬による PPO 更新の有無である。途中の進捗を使う別候補とは独立に採否を判断する。

適用条件・負担・次の判断

学習側で完成系列を評価でき、合法な行動のマスクが得られることが前提になる。実装には系列環境、学習側評価器、PPO 更新が必要で、報酬が疎なため探索と行動への寄与の割当が難しい可能性がある。実計算量は測っていない。今回は共通基準 2 回と本候補 2 回で合成 4 単位を使った。

報酬ログ、実際の学習済み方策、独立した保留評価はない。したがって報酬の増加も実 score の改善も未確認である。次に必要な最小の確認は、同じ分割で実 PPO を動かし、報酬と検証 score を別々に記録した後、候補選択に使っていないデータで改善を確かめること。これは今回の予算と環境の範囲外であり、未実施である。

設計：状態・行動・報酬・更新

架空の一次仕様 S2 が定める入力は、現在の部分系列、残り長、合法手のマスクである。状態を $s_t = (x_{1:t}, 8-t, m_t)$ と置く。m_t が許すトークンを一つ選び系列へ追加し、長さ 8 で終了する。出力は完成系列 $x_{1:8}$。baseline-ppo は保存済み初期方策を更新せず評価する。

本候補の報酬は、学習側評価器 S_{train} によって

$$r_t = \begin{cases} 0 & t < 8, \\ S_{\text{train}}(x_{1:8}) & t = 8 \end{cases}$$

とする。これは S2 の応用設計であり、新しい学習法の提案ではない。既存の PPO 更新を使い、合法手マスクを方策の出力に適用する。設計上は旧方策で系列を収集し、各行動の推定 advantage を使って方策の変化を制限しながら更新する。学習率、割引率、clip 幅、更新回数は fixture に規定がなく、設定したとも実行したとも主張しない。

仮説は「最終目的に沿った報酬で、更新なし方策より検証 score が向上する」。最小の棄却基準は、同一条件の 2seed で改善目安に届かない、または改善方向が安定しないこと。本合成値は改善の目安を満たし、仮説を棄却する結果ではなかった。ただし、実環境の仮説を検証したことにはならない。

データ境界と実際に実行した検証

S2・S3 に従い、データ版は synthetic-v1、分割は group-v1。同一グループを学習と評価にまたがせず、学習用評価器の構築と報酬計算には学習側だけを使う。前処理や設定の選択を必要とする実装では学習側の内部分割で行い、検証 score を報酬へ流し込まない。これは実装上の設計条件であり、probe に学習データや学習処理は存在しない。

実行は次の各組合せを 1 回ずつ。`tools/probe.py` に`--method`、`--seed`、`--output` を渡した。手法は baseline-ppo と terminal-ppo、seed は 1 と 2。候補全体の比較には検証結果を使うため選択バイアスが残る。保留データはなく、評価エピソード ID やチェックポイントも提供されていない。

停止は割当 4 回の完了時。各 seed の差が正であっても、報酬上昇の測定値はない。旧記録の shaped-ppo の 0.95 は random-v0 でグループ重複があり、ソース版も欠落しているため、本比較から除外した。異なる分割の値で本候補を順位づけしていない。

出典と再現情報

[1] 当 fixture `sources.md`、S2「PPO の系列構成環境 v1」：状態・行動・報酬・分割の架空仕様。S3「評価器 v1」：合成値・予算・評価版。2026 年 10 月 20 日参照。外部文献は取得していない。

[2] `README.md`、kaggle 依頼：PPO のみ、score 差 +0.02、seed 1/2、総 6 回・計算枠 1・担当最大 2。

[3] `tools/probe.py`：未変更。SHA256：
`a0f7ebec607d807949f533d349cab56809`
`35d8f82364586f823c1db0f2ebfad0`

[4] 実行出力は `runs/baseline-ppo-1.json`、`baseline-ppo-2.json`、`terminal-ppo-1.json`、`terminal-ppo-2.json`（すべて `runs/`内）。status は completed、各 cost_units=1。設計と全体判断は `notes/terminal-ppo.md`、`.work/ppo.md`。当 fixture 内で利用可能。未保存の実モデル・実データを根拠にしていない。